

Naslov: Diferencijalna evolucija



1. Uvod

Diferencijalna evolucija (DE) optimizaciona metaheuristika, podvrsta evolucionih algoritama, i pripada grupi populacionih metaheuristika, koja održava populaciju potencijalnih rešenja za optimizacioni problem koji se rešava i iterativno pokušava da ih unapredi u odnosu na unapred zadatu meru kvaliteta. Diferencijalna evolucija nema gotovo nikakve pretpostavke o problemu koji rešava, ali takođe nema nikakve garancije da će optimalno rešenje ikada biti pronađeno.

Najčešći slučajevi upotrebe za diferencijalnu evoluciju su višedimenzionalni problemi kontinualne optimizacije. Kako diferencijalna evolucija ne koristi gradijent, optimizacioni problemi koje rešava ne moraju biti diferencijabilni, a čak ne moraju biti ni neprekidni. Zbog toga, diferencijalna evolucija pogoduje za rešavanje najtežih optimizacionih problema, uključujući i probleme sa šumom, ili probleme koji se menjaju kroz vreme.

Prvi put diferencijalna evolucija se pojavljuje 1995. u radu Rajnera Storna i Keneta Prajsa. Od tada su napisane brojne knjige i radovi na temu diferencijalne evolucije koji se bave različitim teoretskim i praktičnim aspektima diferencijalne evolucije.

Iako je diferencijalna evolucija doživela pravu evoluciju, sa raznim novim i hibridnim varijantama algoritma, u osnovi diferencijalne evolucije je ostao jednostavan algoritam. Za svakog člana populacije generiše se novi kandidat, nakon čega se vrši poređenje. Ključna karakteristika diferencijalne evolucije je generisanje kandidata, koje se sastoji iz izbora slučajnih članova populacije, njihovog spajanja u prototip kandidata, i slučajnog izbora karakteristika starog člana koji će novi zadržati.

Pored kontinualnih, diferencijalna evolucija se može koristiti i za probleme diskretne optimizacije. Interno, algoritam i dalje koristi neprekidne vrednosti za kandidate rešenja, a adaptacija se događa u ciljnoj funkciji, odnosno funkciji cene koja zaokružuje ulazne vrednosti do najbližeg celog broja i onda sa zaokruženim vrednostima računa kvalitet rešenja.

2. Algoritam

Diferencijalna evolucija pokušava da unapredi svaku jedinku u populaciji tako što će iskombinovati nekoliko drugih jedinki iz populaciju u skladu sa nekim zadatim jednostavnim pravilom. U svojoj osnovnoj verziji algoritam ima dva parametra, i to su verovatnoća krossovera p i diferencijalna težina ω . Pored ovih parametara, imamo i n_{pop} parametar za veličinu populacije, koja se nasumično

inicijalizuje pre početka rada algoritma. Algoritam se sastoji iz ponavljanja sledećih koraka za svaku jedinku u populaciji.

1. Nasumično izabrati tri različite jedinke a, b i c
2. Konstruisati privremenu jedinku $z = a + \omega \cdot (b - c)$
3. Slučajno izabrati dimenziju $j \in [1, \dots, n_{param}]$,
gde je n_{param} broj dimenzija jedinke, i slučajan broj $r \in [0, 1]$
4. Konstruisati jedinku kandidata x' koristeći binarni crossover
$$x'_i = \begin{cases} z_i, & \text{ako } i = j \text{ ili } r < p \\ x_i, & \text{inače} \end{cases}$$

gde $i \in [1, \dots, n_{param}]$
5. Izabrati bolju jedinku od x i x' za sledeću generaciju

Nakon formiranja nove generacije populacije, prelazi se u sledeću iteraciju, do ispunjenja nekog uslova zaustavljanja, koji takođe mogu imati svoje parametre.

Primetimo da se istraživanje dešava od prvog do četvrtog koraka, a da je peti korak pohlepan i tu se dešava eksploatacija. Zbog pohlepnog petog koraka, algoritam nikada neće prihvatiti lošije rešenje, tako da će se populacija uvek monotono kretati ka optimumu. Sa druge strane, probna jedinka se ne poredi sa celom tekućom populacijom, već samo sa njenim parom iz tekuće populacije, čime se smanjuje pohlepnost petog koraka.

3. Izbor p i ω kontrolnih parametara

Obično veće vrednosti n_{pop} i ω rezultuju robusnom pretragom, ali po ceni sporije konvergencije. Premale vrednosti n_{pop} i ω će dovesti do preuranjene konvergencije ili stagnacije pre pronalaženja globalnog optimuma.

Uobičajeno n_{pop} varira između $2n_{param}$ i $20n_{param}$, mada neki izrazito multimodalni problemi mogu zahtevati i više od $50n_{param}$, dok se za unimodalne i lakše multimodalne probleme preporučuju manje populacije.

Iskustvo govori da vrednosti ω između $2/n_{pop}$ i $1,2$ daju najbolje rezultate. Konkretnu vrednost je potrebno uskladiti sa osobinama ciljne funkcije koja se optimizuje.

Ako nije poznato da je ciljna funkcija razdvojiva, nizak prag verovatnoće p između 0 i $0,1$ je dobar izbor početne vrednosti. Za prag verovatnoće $p = 0$ algoritam je rotaciono invarijantan.

4. Druge varijante diferencijalne evolucije

Vremenom, pojavile su se brojne varijante i modifikacije osnovnog algoritma diferencijalne evolucije. Veliki deo tih modifikacija se odnosio na broj i način izbora jedinki, kao i način konstrukcije jedinke u prva dva koraka. U cilju klasifikacije različitih varijanti, uvedena je notacija

DE/x/y/z,

gde x predstavlja način izbora jedinke koja će biti mutirana, y je broj razlika jedinki koje učestvuju u mutaciji, a z predstavlja crossover shemu. U skladu sa ovom notacijom, osnovna strategija diferencijalne evolucije je označena sa DE/rand/1/bin.

Jedna od popularnih varijacija je DE/best/2/bin, gde mutiramo najbolju jedinku u tekućoj populaciji sa dve razlike jedinki.

$$z = best + \lambda \cdot (a - b) + \omega \cdot (c - d)$$

Tokom prvog koraka ne biramo tri, već četiri jedinke, i uvodimo još jedan parametar λ . Za dovoljno velike populacije, upotreba dve razlike jedinki može da poboljša diverzitet populacije. Mutiranje isključivo najbolje jedinke čini algoritam pohlepni i doprinosi eksploataciji, ali krossover sa tekućom jedinkom ublažava pohlepnost.

5. Samoadaptivni algoritam

Velika prednost algoritma diferencijalne evolucije je što ima mali broj parametara. Podešavanje parametara samo po sebi podrazumeva da imamo neka znanja o ciljnoj funkciji, ili da moramo da se stavimo u ulogu optimizatora i pretražujemo prostor parametara. Tada se pojavila ideja da pustimo optimizator da sam pretražuje prostor parametara.

Stohastička diferencijalna evolucija (SDE) predstavlja samoadaptivnu modifikaciju algoritma diferencijalne evolucije koja sama pretražuje prostor parametara za prag verovatnoće p i diferencijalnu težinu ω . Osnovna varijanta stohastičke diferencijalne evolucije predstavlja modifikaciju strategije DE/rand/1/bin, koja za svaku jedinku u populaciji generiše parametre p i ω .

Na početku algoritma inicijalizujemo posebnu populaciju Ω , tako što za svaku jedinku u populaciji inicijalizujemo ω slučajnom vrednošću iz normalne raspodele $N(0,5, 0,15)$, koje bi uglavnom trebalo da se nalaze u intervalu $[0, 1]$. Zatim, pre drugog koraka generišemo faktor ω za svaku jedinku u populaciji.

$$\omega = \omega_1 + \mathcal{N}(0, 0.5) \cdot (\omega_2 - \omega_3)$$

gde su parametri ω_1, ω_2 i ω_3 slučajno izabrani iz Ω .

Zatim, u četvrtom koraku, umesto parametra praga verovatnoće p uzima se vrednost iz normalne distribucije $N(0,5, 0,15)$, tako da umesto uslova $r < p$, sada koristimo uslov $r < N(0,5, 0,15)$, gde r dolazi iz uniformne raspodele $U(0, 1)$.

Na taj način smo se oslobodili kontrolnih parametara p i ω . Iako je stohastička diferencijalna evolucija prvobitno definisana kao proširenje DE/rand/1/bin strategije, nema razloga zašto ovaj pristup ne bi mogao da se primeni i za druge strategije. Na primer, za DE/best/2/bin bi na sličan način generisali i λ kontrolni parameter. Dalje, nove modifikacije bi mogle da predlože nove načine generisanja težinskih faktora.

Naprednije samoadaptivne varijante samostalno podešavaju i n_{pop} veličinu populacije, u zavisnosti od nekih statistika populacije, uz sofisticiranije metode automatskog podešavanja kontrolnih parametara. Takve varijante su znatno kompleksnije, uvode dosta novih modifikacija i mogu se razmatrati kao poseban algoritam, premda u osnovni zadržavaju bazne korake diferencijalne evolucije.

6. Ograničenja domena pretrage

Kada govorimo o ograničenjima domena pretrage, razmatraju se dve vrste ograničenja, meka i čvrsta ograničenja.

Čvrsta ograničenja predstavljaju okvire prostora pretrage iz kojih jedinke ne smeju da istupe. Ukoliko se prilikom generisanja jedinke otkrije prestup čvrstih ograničenja, modifikuju se tako da se vrate u zadate okvire.

Čvrsta ograničenja se obično zadaju na nivou parametara jedinke, tako da se vrednost parametara koja izađe iz okvira dozvoljenih vrednosti menja nasumično izabranom vrednošću iz okvira parametara.

$$x'_i = \begin{cases} x_{i,lower} + rand \cdot (x_{i,upper} - x_{i,lower}), & \text{ako } x'_i < x_{i,lower} \text{ ili } x_{i,upper} < x'_i \\ x'_i, & \text{inače} \end{cases}, i \in [1, n_{param}]$$

Meka ograničenja, sa druge strane, su granice koje dopuštamo jedinkama da pređu, ali penalizujemo njihov prelazak. Obično se zadaju funkcijama koje vraćaju neutral za dozvoljene vrednosti jedinke, a za nedozvoljene vrednost penala.

Funkcija cene objedinjuje funkcije ograničenja sa ciljnom funkcijom. Za definisanje funkcije cene obično se koriste aditivni i multiplikativni pristup. Aditivni pristup podrazumeva da se vrednosti koje vrte g funkcije ograničenja sabere sa vrednošću koju vrati $f_{objective}$ ciljna funkcija.

$$f_{cost}(x) = f_{objective}(x) + \sum_{i=1}^{n_{param}} g_i(x)$$

Multiplikativni pristup obično podrazumeva množenje vrednosti ciljne funkcije sa stepenovanim vrednostima funkcija ograničenja. Neutral za aditivni pristup nula, a neutral za multiplikativni je jedan. Pored toga što u multiplikativnom pristupu moramo da obezbedimo da funkcije ograničenja vraćaju jedinicu ako je sve uredu, moramo da obezbedimo i da ciljna funkcija konvergira ka jedinici sa desne strane. Time unosimo dodatne pretpostavke o funkciji, tako da se multiplikativni pristup retko koristi.

7. Uslovi zaustavljanja

Sam algoritam diferencijalne evolucije ne definiše uslove zaustavljanja,

8.Implementacija

9.Test funkcije

10.Rezultati

11.Zaključak

12.Reference

Feoktistov, Vitaliy. Differential Evolution: In Search of Solutions. Springer, 2006.

Kochenderfer, Mykel J., and Tim A. Wheeler. Algorithms for Optimization. MIT Press, 2019.

Lampinen, Jouni, and Ivan Zelinka. "Mixed Variable Non-Linear Optimization by Differential Evolution." In Proceedings of Nostradamus'99, 2nd International Prediction Conference, edited by Ivan Zelinka, 45-55. Zlin, Czech Republic: Technical University of Brno, Faculty of Technology Zlin, Department of Automatic Control, 1999. ISBN 80-214-1424-3.

Storn, Rainer, and Kenneth Price. "Differential Evolution—A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces." Journal of Global Optimization 11, no. 4 (1997): 341–359.

Storn, Rainer, and Kenneth Price. "Differential Evolution - A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces." Journal of Global Optimization 11, no. 4 (1997): 341-359. Kluwer Academic Publishers.

Price, Kenneth V., Rainer M. Storn, and Jouni A. Lampinen. Differential Evolution: A Practical Approach to Global Optimization. Natural Computing Series. Springer, 2005.

Omran, Mahamed G. H., Ayed Salman, and Andries P. Engelbrecht. "Self-adaptive Differential Evolution." In Evolutionary Computation, edited by A. E. Eiben et al., 2005. Springer-Verlag Berlin Heidelberg.

AlKhulaifi, Dania, Maryam AlQahtani, Zenab AlSadeq, Atta-ur Rahman, and Dhiaa Musleh. "An Overview of Self-Adaptive Differential Evolution Algorithms with Mutation Strategy." Mathematical Modelling of Engineering Problems 9, no. 4 (2022).