

Diferencijalna evolucija

Miloš Đurić 191/2018

Matematički fakultet – Univerzitet u Beogradu

Uvod

- Populaciona metaheuristika
- Objavljena 1995.
- Koristi se za kontinualnu optimizaciju
- Ne pretpostavlja diferencijabilnost, ni neprekidnost



Algoritam

- Inicijalizacija: Generisati populaciju od N jedinki
- Evaluacija: Oceniti svaku jedinku u populaciji
- Dok nije ispunjen uslov zaustavljanja ponavljaj
 - Selekcija: Izabrati jedinke iz populacije koje će dati nove jedinke
 - Varijacija: Primeniti operatore varijacije i napraviti nove jedinke
 - Evaluacija: Oceniti jedinke u novoj populaciji
 - Preživljavanje: Izabrati jedinke iz nove i tekuće populacije i formirati novu generaciju
- Kraj rada algoritma

Konstrukcija jedinke i izbor parametara

- Prvobitna verzija diferencijalne evolucije je za slučajne a , b i c generisala nove nove jedinke prema formuli

$$z = a + \omega \cdot (b - c)$$

- Varijacija između nove jedinke x i stare jedinke z je vršena po hromozomima, gde je j slučajan index, a r slučajna vrednost $(0, 1)$

$$x'_i = \begin{cases} z_i, & \text{ako } i = j \text{ ili } r < p \\ x_i, & \text{inače} \end{cases}$$

- Preporučene vrednosti omega su od $1/n_{pop}$ do 1.2, a za p od 0 do 0.1

Druge varijante DE

- Uvodi se notacija DE/x/y/z
 - x - način izbora jedinke koja će biti mutirana
 - y - broj razlika jedinki koje učestvuju u mutaciji
 - z - crossover shemu
- Osnovna strategija je DE/rand/1/bin
- Popularna strategija DE/best/2/bin
$$z = best + \lambda \cdot (a - b) + \omega \cdot (c - d)$$
- Za velike populacije poboljšava diverzitet.

Stohastička diferencijalna evolucija (SDE)

- Samoadaptivna modifikacija diferencijalne evolucije
- Za svaku jedinku u populaciji generišemo kontrolne parametre.
- Faktor mutacije inicijalno generiše iz $N(0,5, 0,15)$, a zatim po iteracijama

$$\omega = \omega_1 + \mathcal{N}(0, 0.5) \cdot (\omega_2 - \omega_3)$$

- Umesto parametra p koristimo normalnu raspodelu, tako da

$$r < N(0,5, 0,15)$$

- Osnovna modifikacija se odnosi na DE/rand/1/bin, ali može se adaptirati i za druge strategije

Ograničenja domena pretrage

- Čvrsta ograničenja

$$x'_i = \begin{cases} x_{i,lower} + rand \cdot (x_{i,upper} - x_{i,lower}), & \text{ako } x'_i < x_{i,lower} \text{ ili } x_{i,upper} < x'_i \\ x'_i, & \text{inače} \end{cases}, i \in [1, n_{param}]$$

- Meka ograničenja ne isključuju jedinke koje izažu iz granica, već ih penalizuju kroz funkcije ograničenja
- Funkcija cene objedinjuje ciljnu funkciju i funkcije ograničenja

$$f_{cost}(x) = f_{objective}(x) + \sum_{i=1}^{n_{param}} g_i(x)$$

Uslovi zaustavljanja




Test funkcije


- Korišćeno 10 funkcija, sa osmodimenzionim argumentima
- Primer: Šekelova funkcija

$$f(X) = \sum_{i=1}^m \left(c_i + \sum_{j=1}^n (x_j - a_{ji})^2 \right)^{-1}, -\infty \leq x_i \leq \infty$$


2D Shekel function



Šekelova funkcija: Istorija najboljih ocena



Šekelova funkcija: Istorija dverziteta



Zaključak

- Diferencijalna evolucija je postigla bolje ili slične rezultate kao algoritmi iz biblioteka `scipy.optimize` i `mistic`
- Samoadaptivni algoritmi sporije konvergiraju, ali održavaju veću raznolikost populacije